

NeuroTransmitiendo

Machine Learning

Dr. Gustavo Juantorena

LIAA
Laboratorio de Inteligencia Artificial Aplicada

¿Quién soy?

- Biólogo (UBA), especializado en neurociencias.
- Doctorado en Ciencias de la Computación en el Laboratorio de Inteligencia Artificial Aplicada (UBA-CONICET).
- Trabajo en psiquiatría computacional e IA aplicada a la detección de patologías neurológicas.
- Docente y divulgador.



¿Qué nos llevamos de este curso?

1

Ubicar al ML

Entender qué es la inteligencia artificial y qué lugar ocupa el machine learning.

2

Hablar el idioma

Supervisado, no supervisado, clasificación, regresión, sobreajuste.

3

Evaluar bien

Saber cuándo un modelo realmente predice y cuándo nos estamos engañando.

4

Leer métricas

Matriz de confusión, sensibilidad, especificidad, AUC y error de regresión.

Temas del curso

01 **IA y machine learning**
Qué es y de dónde viene

02 **Conceptos básicos**
Supervisado, no supervisado

03 **Evaluación**
¿Realmente predice?

04 **Métricas**
Cómo medir un modelo

05 **TMT digital**
Un caso real

06 **Cierre**
Cuidados y recursos

Módulo 1

Inteligencia artificial y machine learning

- ¿Qué es la IA? Una brevísima historia
- Qué es el machine learning
- Deep learning e IA generativa
- ¿Cómo funciona ChatGPT?

NeuroTransmitiendo

¿De qué hablamos cuando hablamos de IA?



Claude



deepseek

Para pensar

¿Qué tienen en común estas herramientas?

¿Piensan? ¿Entienden? ¿Aprenden?

Una brevísima historia

1950

Turing propone el juego de la imitación

1956

Conferencia de Dartmouth: nace el nombre «inteligencia artificial»

1966

ELIZA, el primer chatbot

1950-1990

IA simbólica (reglas) e IA conexionista (redes)

2010s

Deep learning: ganan las redes

2020s

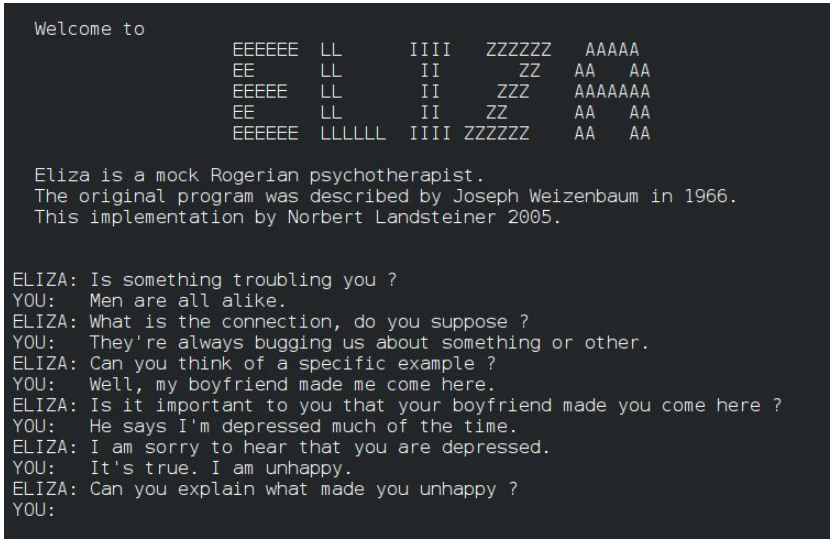
IA generativa: ChatGPT y compañía



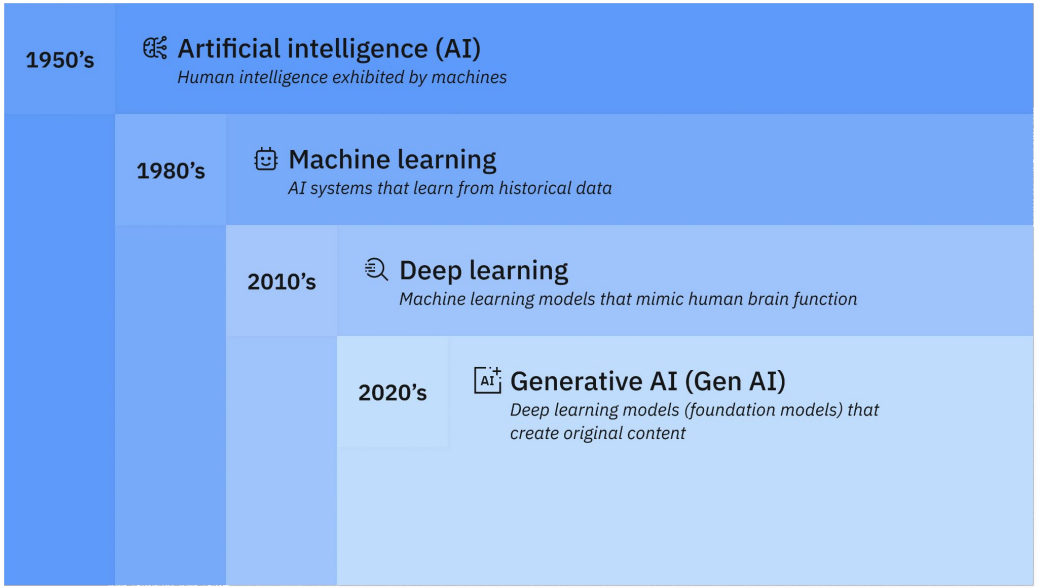
Alan Turing: «Las máquinas pueden pensar», si redefinimos qué significa pensar.

ELIZA: el primer chatbot era... un psicoterapeuta

- Creado en el MIT por Joseph Weizenbaum en 1966.
- Imitaba a un terapeuta rogeriano: respondía con preguntas genéricas.
- *«Me siento triste» → «¿Por qué te sentís triste?»*
- Funcionaba con reglas escritas a mano: detectaba patrones y los reorganizaba.
- **No entendía nada,** pero generaba la ilusión de comprensión.



Entonces, ¿qué es la IA?



- La IA es el campo general.
- El machine learning es una forma de hacer IA: aprender de datos.
- El deep learning es un tipo de machine learning.
- La IA generativa es un uso del deep learning.

Fuente: IBM, «What is artificial intelligence?»

Dos formas de construir un sistema inteligente

Escribir reglas

- Una persona experta escribe las reglas a mano.
- Ejemplo: «si tiene 4 patas y ladra, es un perro».
- Funciona mientras el problema sea simple y las reglas se puedan explicitar.

Aprender de ejemplos

- Le damos a la computadora muchos casos ya resueltos.
- Ejemplo: cientos de imágenes de animales con sus etiquetas.
- El algoritmo encuentra las reglas solo. **Esto es machine learning.**

«Un programa aprende de la experiencia E, con respecto a una tarea T y una medida de desempeño P, si su desempeño en T, medido por P, mejora con E.»

Tom Mitchell (1997), Machine Learning



Tarea, medida y experiencia: un ejemplo



T

Tarea

Clasificar una foto como muffin o chihuahua.

P

Medida

Porcentaje de fotos bien clasificadas (accuracy).

E

Experiencia

Muchas fotos ya etiquetadas como perro o muffin.

Algoritmo y modelo: no son lo mismo

Algoritmo: una receta de pasos bien definidos que transforma una entrada en una salida.



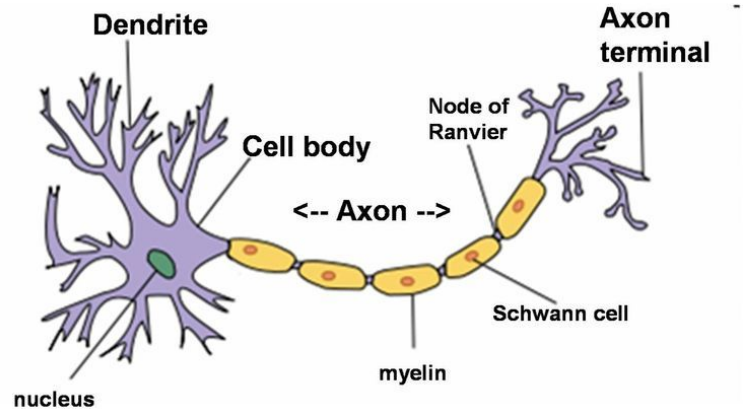
Modelo: lo que resulta de aplicar un algoritmo de aprendizaje a los datos.



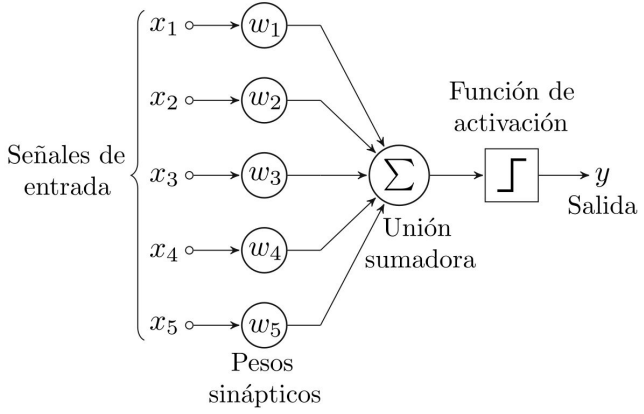
entrenamiento

El modelo es lo que después usamos para predecir casos nuevos.

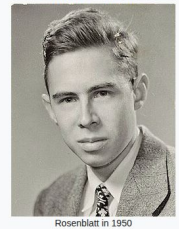
Deep learning: “inspirado” en las neuronas



Neurona biológica

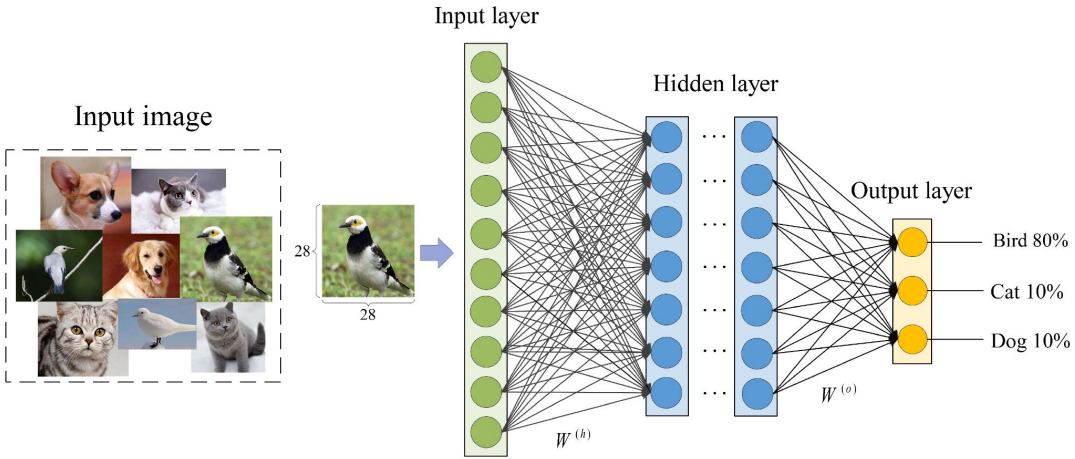


Perceptrón (Rosenblatt, 1957)


Rosenblatt in 1950

El perceptrón suma entradas con distintos pesos y «se activa» si la suma supera un umbral.
Aprender es ajustar esos pesos.

Muchas capas: redes neuronales profundas

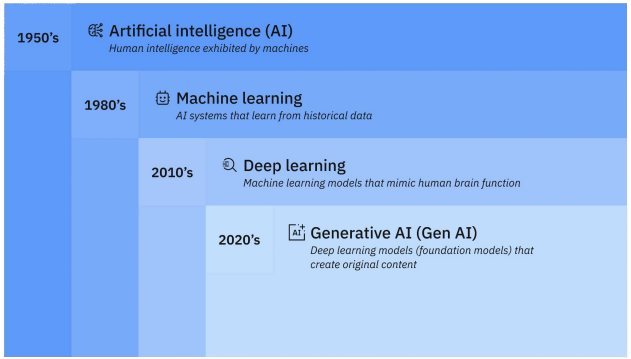


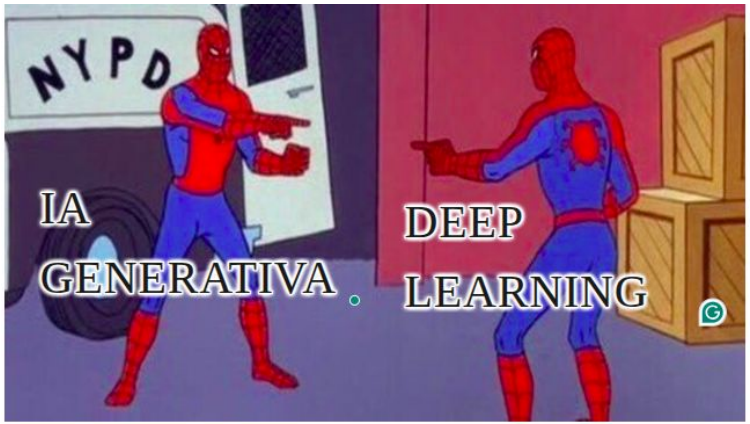
¿Por qué «profundo»?

- Se apilan muchas capas de neuronas artificiales.
- Cada capa aprende rasgos cada vez más abstractos.
- Necesitan muchísimos datos y poder de cómputo.

IA generativa

- Modelos de deep learning que crean contenido nuevo: texto, imágenes, audio o video.
- Aprenden una representación simplificada de sus datos de entrenamiento.
- A partir de esa representación generan algo parecido, pero no idéntico, a lo que vieron.





La IA generativa es deep learning

De palabras a números

1. Un número por palabra

teléfono = 1

carpincho = 2

tostadora = 3

Problema: para la computadora, dos teléfonos dan un carpincho.

2. One-hot

teléfono = (1, 0, 0)

carpincho = (0, 1, 0)

tostadora = (0, 0, 1)

Problema: todas las palabras quedan igual de lejos.

3. Embeddings

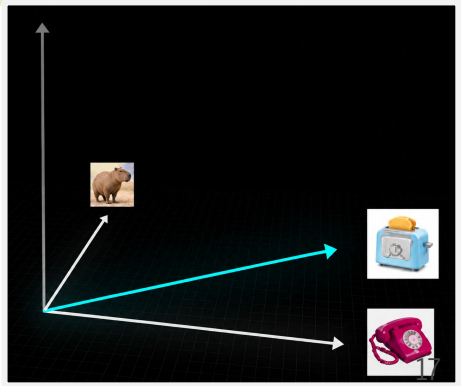
teléfono = (0.1, 0.9, 0.2)

tostadora = (0.2, 0.8, 0.1)

carpincho = (0.9, 0.1, 0.7)

Solución: lo parecido queda cerca, como teléfono y tostadora.

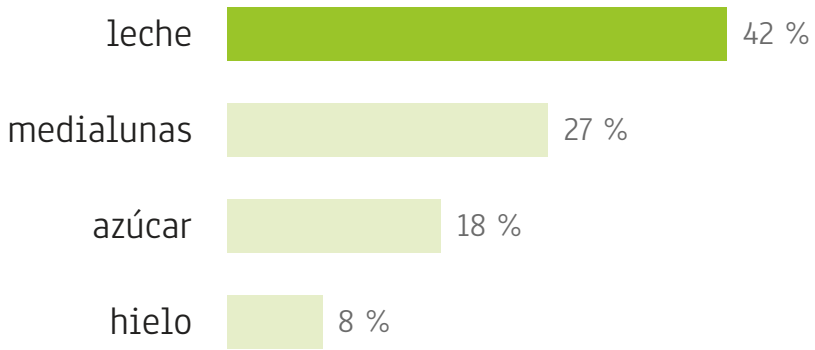
Las posiciones se aprenden del contexto:
palabras en frases parecidas quedan cerca.



¿Cómo funciona ChatGPT?

GPT: Generative Pre-trained Transformer. Es un modelo que **predice la siguiente palabra.**

«Hoy a la mañana me tomé un café con...»



1. Preentrenamiento

Lee enormes cantidades de texto y aprende a predecir la palabra siguiente.

2. Ajuste fino

Personas escriben respuestas ideales y comparan respuestas para que se comporte como asistente.

Fuente: Andrej Karpathy (2023), Intro to Large Language Models

Resumen del módulo 1

IA

El campo general: máquinas que imitan capacidades humanas.

Machine learning

Aprender reglas a partir de ejemplos en lugar de escribirlas.

Deep learning

Machine learning con redes neuronales de muchas capas.

IA generativa

Deep learning que produce contenido “nuevo” en base a lo que fue entrenado.

Módulo 2

Conceptos básicos

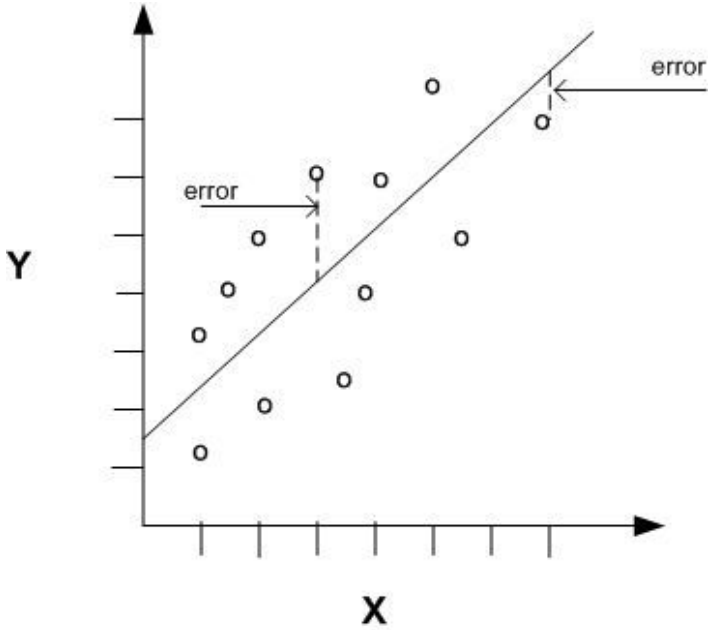
- Explicar, predecir y causalidad
- Supervisado y no supervisado, extracción de variables
- Modelos lineales: regresión lineal y logística
- Sobreajuste y regularización
- Modelos no lineales e interpretabilidad

NeuroTransmitiendo

«Todos los modelos están equivocados, pero algunos son útiles.»

George E. P. Box

Un modelo es una simplificación



y = pendiente · x + ordenada

- La recta resume la relación entre dos variables.
- Ningún punto cae exactamente sobre la recta.
- **Entrenar** es buscar la recta que minimiza el error.

¿Explicar o predecir?

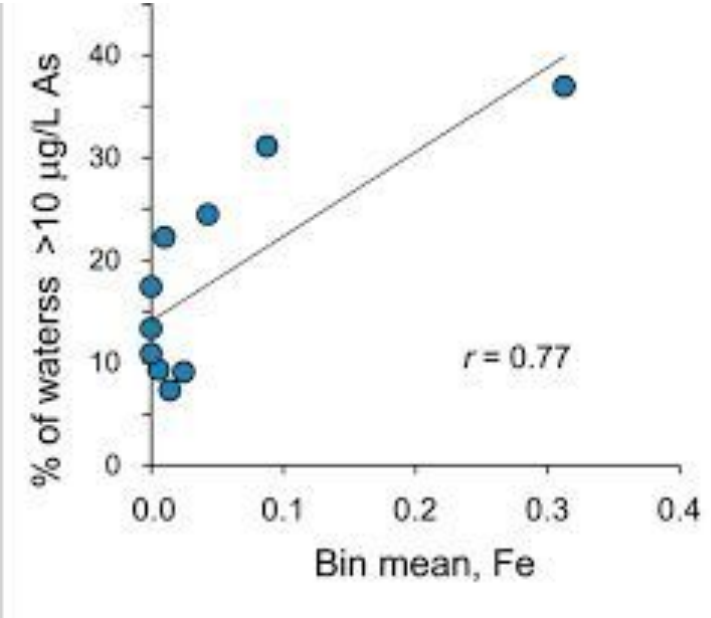
Explicar (estadística clásica)

- ¿Qué relación hay entre las variables?
- Modelos simples e interpretables.
- Se trabaja sobre la muestra y se infiere a la población: p-valores, intervalos.

Predecir (machine learning)

- ¿Qué tan bien anticipa el modelo casos nuevos?
- Se admiten modelos complejos si predicen mejor.
- Se evalúa siempre con datos **que el modelo no vio.**

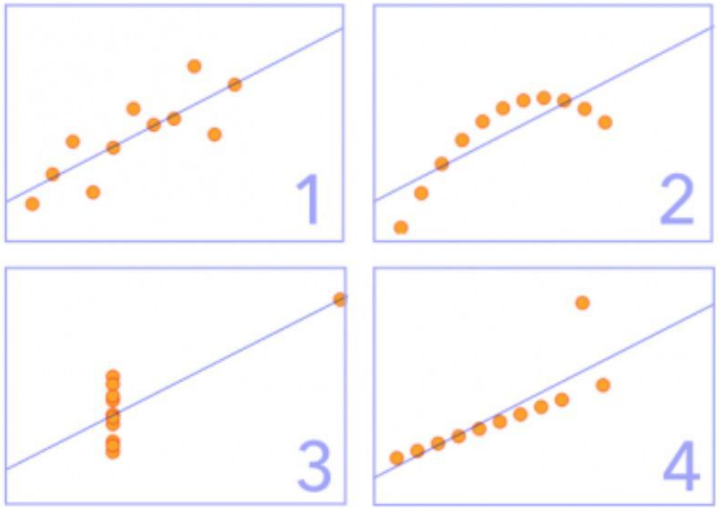
Correlación no implica predicción (ni causalidad)



Poldrack, Huckins y Varoquaux (2020), JAMA Psychiatry

- La correlación es alta y significativa (r = 0.77).
- Pero depende casi por completo de un solo punto.
- Como predictor de casos nuevos sería **terrible.**
- Regla: no usar la palabra «predecir» si no medimos el desempeño en **datos nuevos.**

Siempre visualizá los datos



Cuarteto de Anscombe

- Cuatro conjuntos de datos con la misma **media**, **varianza**, **correlación** y **recta de regresión**.
- Un número resumen nunca alcanza.

Asociación, predicción y causalidad

Asociación

¿Las variables van juntas?

Correlación, regresión, p-valores.

Predicción

¿Puedo anticipar casos nuevos?

Se evalúa con datos que el modelo no vio.

Causalidad

¿Si cambio una, cambia la otra?

Requiere experimentos o supuestos fuertes.

Predicción no implica causalidad. Si el tono de voz predice ansiedad social, eso no significa que cambiar el tono de voz cambie la ansiedad.

Cuidado también al **ajustar por variables**: incluir la variable equivocada puede crear asociaciones que no existen.

Tipos de aprendizaje automático



Aprendizaje supervisado (hay etiqueta)

Cada caso viene con sus **variables** (lo que medimos) y su **etiqueta** (lo que queremos predecir).

Participante	Edad	Años de educación	Puntaje de memoria	Diagnóstico
P01	71	12	27	Control
P02	78	9	19	Deterioro Cognitivo
P03	69	16	28	Control
P04	80	14	21	Deterioro Cognitivo
P05	75	11	24	?

Aprendizaje supervisado (hay etiqueta)

Cada caso viene con sus **variables** (lo que medimos) y su **etiqueta** (lo que queremos predecir).

Participante	Edad	Años de educación	Puntaje de memoria	Diagnóstico
P01	71	12	27	Control
P02	78	9	19	Deterioro Cognitivo
P03	69	16	28	Control
P04	80	14	21	Deterioro Cognitivo
P05	75	11	24	?



Queremos predecirlo!

Extracción de variables

Dato crudo		Variables que se extraen
Texto	*«Hoy no tengo ganas de nada»* →	Sentimiento, palabras de emoción, pronombres en primera persona
Voz	*Una grabación de audio* →	Pausas, velocidad del habla, tono

Clasificación y regresión

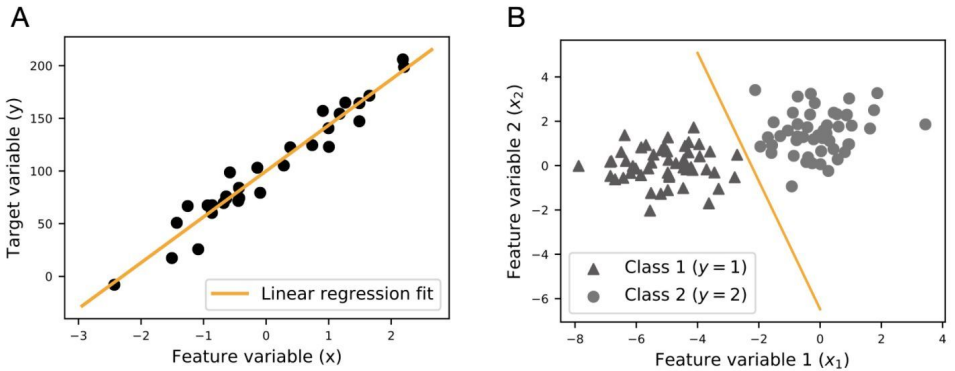


Figure 3. Illustrations of the two main categories of supervised learning, regression (A) and classification (B).

A la izquierda, una recta que sigue la tendencia. A la derecha, una frontera que separa dos grupos.

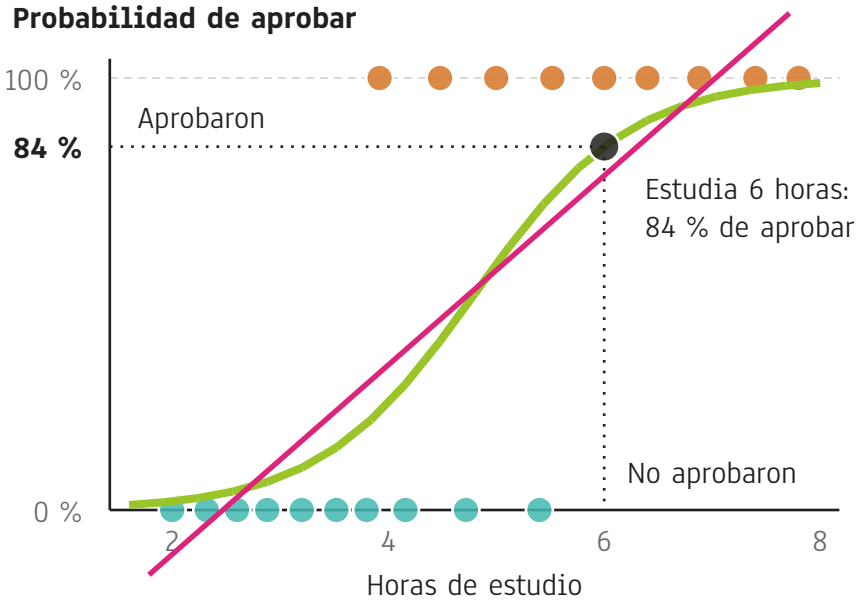
Regresión

La etiqueta es un número. Ejemplo: predecir el puntaje de un test psicológico..

Clasificación

La etiqueta es una categoría. Ejemplo: presencia o ausencia de una patología..

Regresión logística



Rosa: regresión lineal. Verde: regresión logística. Datos simulados.

- Queremos predecir sí o no: ¿la persona aprueba el examen?
- Una recta (regresión lineal) da valores **por debajo de 0 o por encima de 100 %**, que no sirven como probabilidad.
- La regresión logística dobla la recta en **forma de S**: el resultado queda siempre entre 0 y 100 %.
- Ese número es una **probabilidad**. Para decidir se elige un umbral, que vemos en el módulo 4.

Escalas de medición y tipo de problema

Escala	Ejemplo	Tipo de problema
Nominal	Diagnóstico: control, deterioro cognitivo leve, demencia	Clasificación
Ordinal	Ítem Likert de 1 a 5	Depende: a veces clasificación, a veces regresión
Intervalar	Puntaje estandarizado (z)	Regresión
Razón	Tiempo de reacción en segundos	Regresión

El tipo de variable que queremos predecir define el tipo de problema.

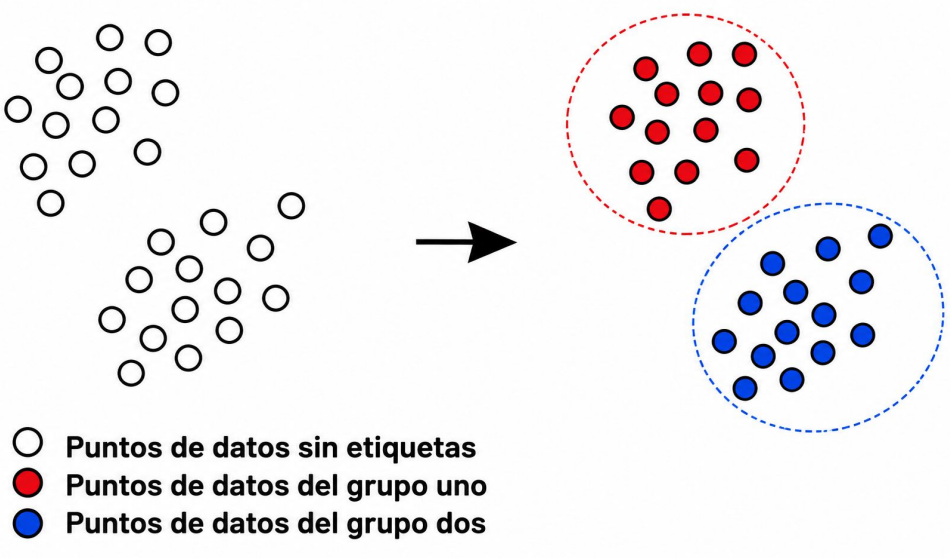
¿Clasificación o regresión?

1. Predecir si un paciente va a abandonar el tratamiento.
2. Predecir el puntaje del inventario de depresión de Beck.
3. Predecir qué tipo de trastorno de ansiedad tiene una persona.
4. Predecir cuántas sesiones va a necesitar un paciente.

¿Clasificación o regresión?

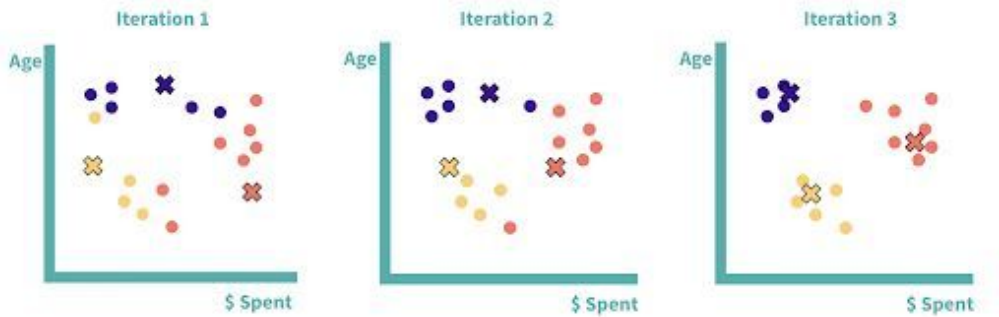
1	Predecir si un paciente va a abandonar el tratamiento.	C
2	Predecir el puntaje del inventario de depresión de Beck.	R
3	Predecir qué tipo de trastorno de ansiedad tiene una persona.	C
4	Predecir cuántas sesiones va a necesitar un paciente.	R

Aprendizaje no supervisado (no hay etiqueta)



- Solo tenemos las variables, sin respuesta correcta.
- El objetivo es descubrir **estructura**: grupos de casos parecidos.
- Ejemplo: perfiles de pacientes según sus síntomas, sin decirle al algoritmo qué perfiles buscar.
- Ojo: el algoritmo siempre encuentra grupos, **aunque no existan**.

Un algoritmo de clustering: k-means



Paso 1

Elegimos cuántos grupos queremos (k).

Paso 2

Ubicamos k centros al azar.

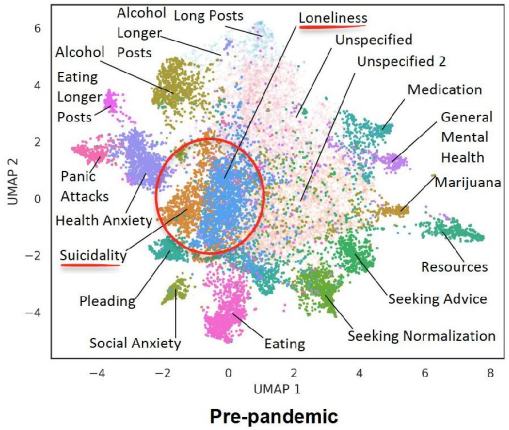
Paso 3

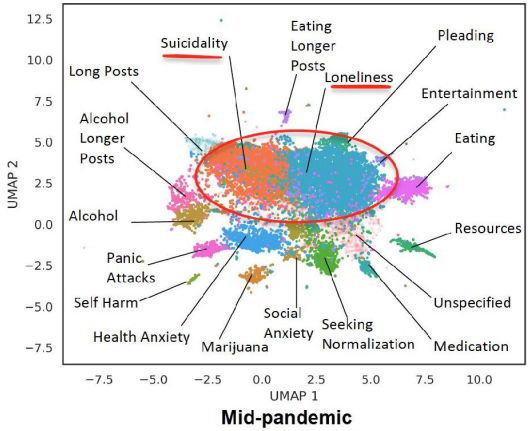
Asignamos cada punto al centro más cercano.

Paso 4

Movemos cada centro al promedio de su grupo y repetimos.

Reducción de dimensionalidad





Low y colaboradores (2020), JMIR: posteos de Reddit sobre salud mental

- Resume muchas variables en unas pocas.
- Permite visualizar datos complejos en dos dimensiones.
- Ejemplos: PCA, emparentado con el análisis factorial, y UMAP.
- En el ejemplo, cada punto es un posteo de Reddit descrito por cientos de variables lingüísticas

Parámetros e hiperparámetros

Parámetros

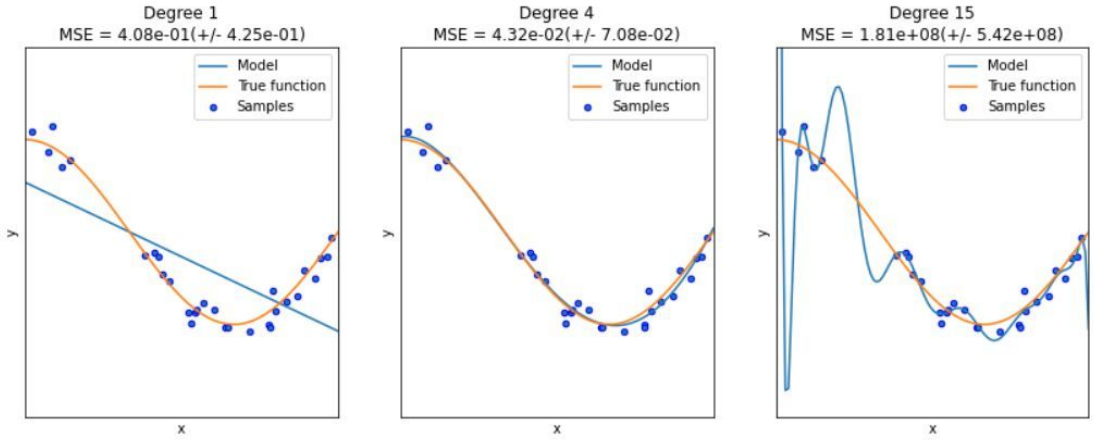
- Los aprende el modelo a partir de los datos.
- Ejemplo: la pendiente y la ordenada de la recta.
- Son «las reglas aprendidas».

Hiperparámetros

- Los elegimos nosotros antes de entrenar.
- Ejemplo: cuántos grupos busca k-means o qué tan complejo puede ser el modelo.
- Probar combinaciones es parte del trabajo.

Algoritmo + hiperparámetros = una **configuración**. Buscar la mejor configuración también hay que evaluarlo bien (módulo 3).

Subajuste y sobreajuste



Subajuste

Modelo demasiado simple: no captura el patrón.

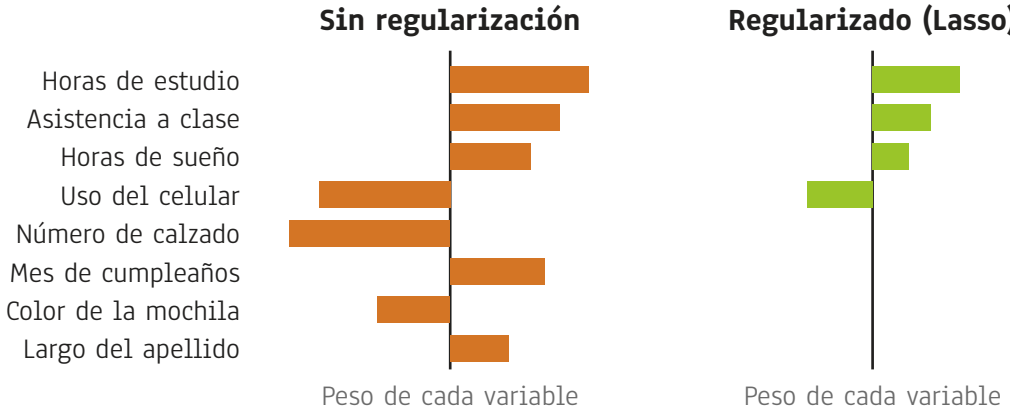
Buen ajuste

Captura el patrón general.

Sobreajuste

Aprende hasta el ruido de la muestra: no generaliza.

Regularización

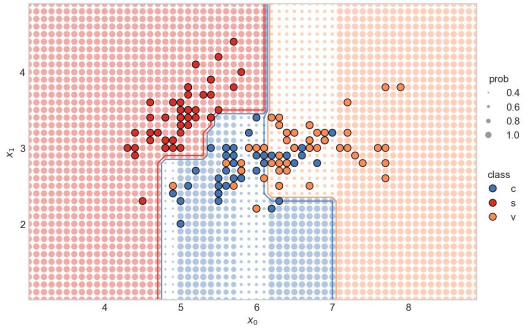


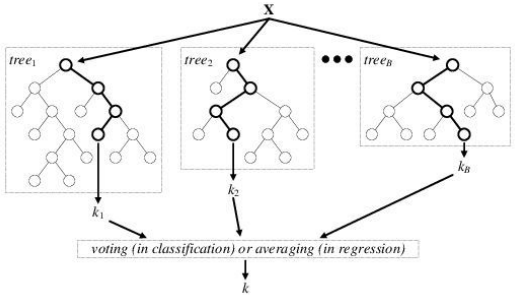
Ejemplo ilustrativo: predecir si una persona aprueba un examen.

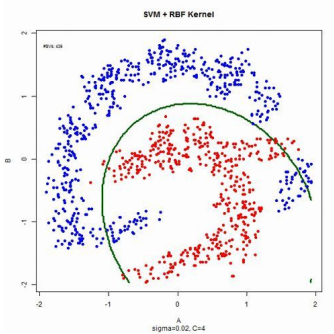
- Se **penaliza** al modelo cuando usa pesos grandes.
- Así no puede ajustarse a cada detalle de la muestra: puede reducir el sobreajuste.
- **Ridge** achica todos los pesos. **Lasso** lleva algunos a cero y descarta variables.
- Cuánto penalizar es un hiperparámetro.

Muy útil cuando hay muchas variables y pocas personas, **algo habitual en estudios con personas.**

Algunos modelos no lineales







Árbol de decisión

Preguntas sucesivas del tipo «¿el tiempo supera X?».

Random forest

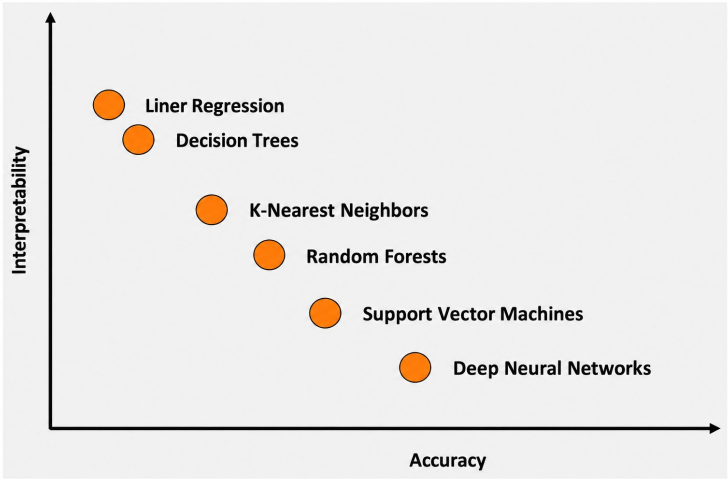
Muchos árboles distintos que votan.

SVM con kernel

Fronteras curvas entre grupos.

Las redes neuronales del módulo 1 también son no lineales. Más flexibilidad implica más riesgo de sobreajuste.

Interpretabilidad: ¿qué aprendió el modelo?



Más desempeño suele implicar menos interpretabilidad

- **Modelos lineales:** los pesos dicen qué variables importan y en qué dirección.
- **Importancia por permutación:** se mezcla una variable y se mide cuánto empeora el modelo.
- **SHAP:** estima cuánto aporta cada variable a cada predicción. Lo vamos a ver en el módulo 5.
- **Importante:** importancia para predecir no es causalidad.

Resumen del módulo 2

Explicar o predecir

Son objetivos distintos. Predecir se mide en datos nuevos.

Supervisado

Hay etiqueta. Clasificación si es categoría, regresión si es número.

No supervisado

No hay etiqueta. Se buscan grupos o se resumen variables.

Sobreajuste

Un modelo que memoriza la muestra no sirve para casos nuevos.

Módulo 3

Evaluación

- ¿Por qué es tan fácil evaluar mal?
- Separar los datos: entrenamiento y control
- Validación cruzada
- Separar por persona: group k-fold
- Baselines

NeuroTransmitiendo

Es fácil equivocarse al entrenar un modelo, pero también es fácil darse cuenta.

Es fácil equivocarse al evaluarlo… y muy difícil darse cuenta.

¿Qué puede salir mal?

Evaluar con los datos de entrenamiento

Es como tomar un examen con las mismas preguntas de la práctica.

Datos que no representan la realidad

La muestra no se parece a la población donde se va a usar.

Pocos datos para evaluar

El resultado cambia mucho si cambian unos pocos casos.

Grupos ocultos en los datos

Varias mediciones de la misma persona, o de un mismo hospital.

Métricas mal elegidas

Un número alto que no mide lo que nos importa.

Sin punto de comparación

Un 70 % no dice nada si no sabemos cuánto da algo trivial.

Un caso real: predicción de embarazo adolescente en Salta

Sobre la predicción automática de embarazos adolescentes

> Tras estudiar la metodología del sistema de inteligencia artificial supuestamente capaz de predecir embarazos adolescentes, mencionado por el Gobernador de Salta, Juan Manuel Urtubey, encontramos serios errores técnicos y conceptuales, que ponen en duda los resultados reportados y comprometen el empleo de dicha herramienta, sobre todo tratándose de una cuestión tan sensible.

El 11/4/2018, en el programa de televisión "El Diario de Mariana", el Gobernador de Salta, Juan Manuel Urtubey, describió un sistema de inteligencia artificial supuestamente capaz de predecir

- En 2018 se anunció un sistema que "predecía" embarazos adolescentes.
- Se reportaron resultados sobreestimados por errores de evaluación.
- Los datos no eran adecuados para el objetivo declarado.
- **Lección:** las decisiones de evaluación tienen consecuencias reales sobre personas.

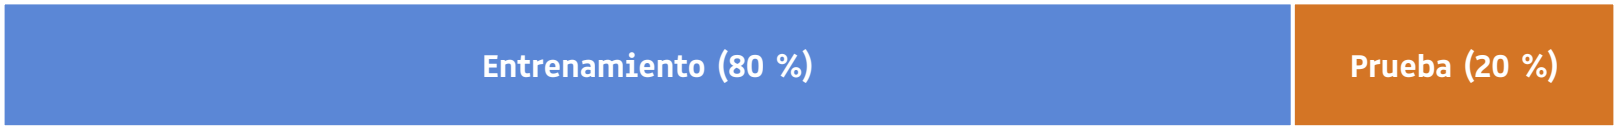
Fuente: Análisis del Laboratorio de Inteligencia Artificial Aplicada (UBA)
https://www.liaa.dc.uba.ar/sobre-la-prediccion-automatica-de-embarazos-adolescentes/

¿100 % de accuracy? ¿Mejor que un experto?

Una metodología estricta minimiza los errores. Y nunca hay que dejar de ser críticos.

¿Cuándo podemos decir que un modelo predice?

1. Dividí los datos en dos partes.
2. El modelo aprende solo con una parte: entrenamiento.
3. Evaluás el modelo con la otra parte, que nunca vio.



Los datos se reparten al azar entre las dos partes.

El conjunto de control: la caja fuerte



- Antes de hacer nada, separamos una parte de los datos y la guardamos bajo llave.
- Se usa **una sola vez**, al final: antes de publicar el paper o de usar el modelo con pacientes.
- **No se puede** usar para tomar decisiones: elegir modelo, variables o umbral.
- ¿No nos gusta el resultado? **Se reporta igual.**
- En la bibliografía aparece como test set, held-out set o conjunto de evaluación.

Flujo de trabajo en tres fases

Fase 0: Separar el control → **Fase 1: Desarrollo** → **Fase 2: Medición final**

Fase 0: Separar el control	Fase 1: Desarrollo	Fase 2: Medición final
Lo antes posible. Se guarda y no se mira.	Explorar datos, probar configuraciones, analizar errores, elegir la mejor.	Entrenar la configuración elegida y medir una sola vez en el control.

Entre fase y fase hay un **punto de no retorno**: si miramos el control para decidir algo, deja de ser una medición honesta.

Para jugar: separar los datos



Entrenamiento, validación y control, con perros y gatos:

mlu-explain.github.io/train-test-validation

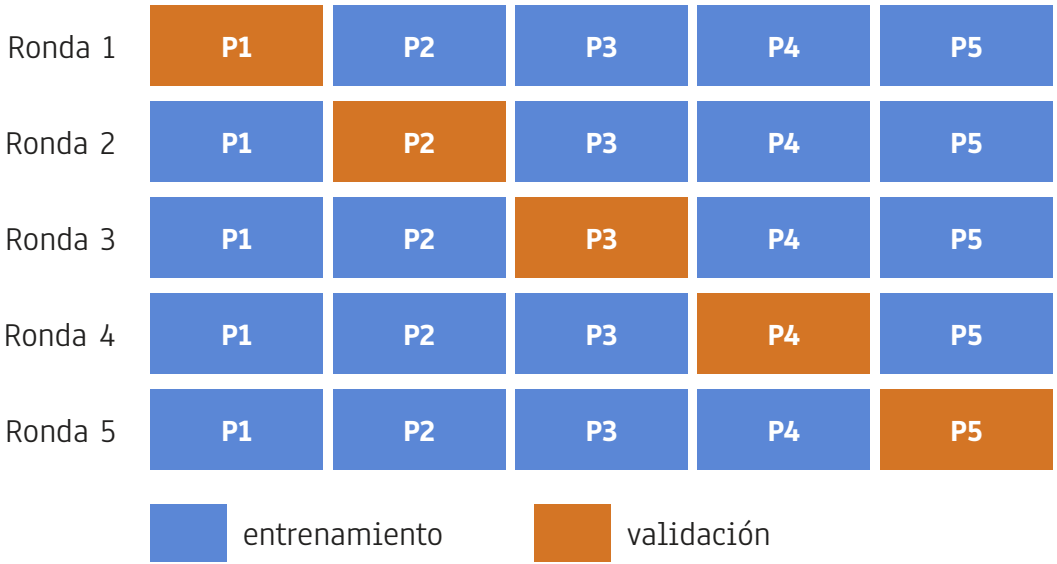
Ojo con los nombres: lo que la página llama test es nuestro conjunto de control.

Un problema: ¿y si tuvimos mala suerte al separar?

Entrenamiento	Validación

- Si medimos sobre una sola porción chica, el resultado depende de qué casos cayeron ahí.
- *Anécdota real: «me dio 83 % para tal clase, pero si saco una sola persona me da 62 %».*
- El problema es mayor cuando hay pocos datos, algo muy común en estudios con personas.
- Solución: usar **todos** los datos para evaluar, por turnos. Eso es la validación cruzada.

Validación cruzada de k particiones (k-fold)



1. Dividimos los datos en k partes.
2. Entrenamos con k - 1 y predecimos la que quedó afuera.
3. Rotamos hasta que cada parte fue validación una vez.
4. Juntamos todas las predicciones y calculamos la métrica.

Para pensar: ¿la validación cruzada evita el sobreajuste?



Para pensar: ¿la validación cruzada evita el sobreajuste?

No.

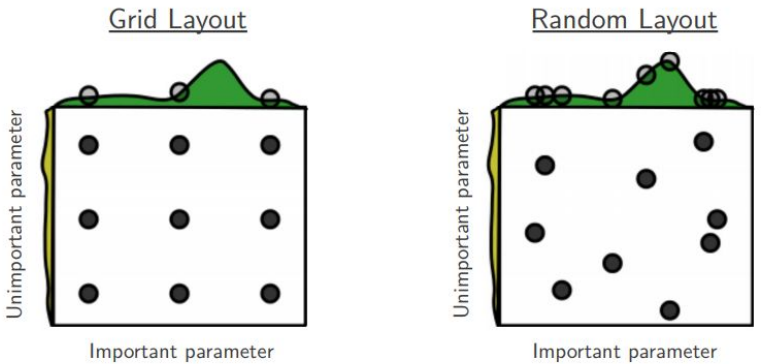
La validación cruzada no hace que el modelo sea mejor.

Hace que la estimación de qué tan bueno es sea más honesta.

Nos permite **detectar** el sobreajuste, no evitarlo.



Optimización: buscar la mejor configuración

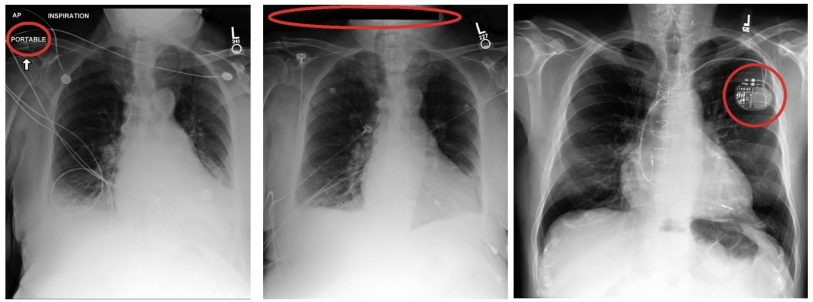


Bergstra y Bengio (2012)

- **Manual:** probar valores que creemos razonables.
- **En grilla:** probar todas las combinaciones de una lista.
- **Aleatoria:** probar combinaciones al azar. Con el mismo esfuerzo suele explorar mejor.

Cada configuración se compara con validación cruzada **dentro de los datos de desarrollo.** Nunca con el conjunto de control.

Atajos que el modelo aprende sin avisar



Hospital tags Stripes Medical devices

Figure 2: Hospital tags, strips, and medical devices exemplify several unknown group labels in the MIMIC-CXR dataset, which might spuriously correlate with the ground truth diagnosis results.

Ye y colaboradores (2024), Spurious correlations in machine learning

- Si se sospecha cáncer, el paciente va al hospital A. Si no, al hospital B, donde las imágenes salen más claras.
- El modelo llega al 99 %… porque **aprendió a reconocer el hospital**.
- Es una **correlación espuria**: en un hospital C, el modelo falla.

¿Cómo separarían estos datos?

Detección de emociones en la voz

Tenemos 2000 grabaciones, pero de solo 10 personas.

¿Qué pasa si grabaciones de la misma persona quedan en entrenamiento y en validación?

Una tarea con muchos ensayos

Cada participante hace 20 ensayos de una prueba.

¿Cuál es la pregunta: predecir ensayos nuevos o personas nuevas?

Clave: ¿a qué queremos generalizar?

Separar por persona: group k-fold

Mal: ensayos mezclados al azar



entrenamiento | validación

Bien: cada persona entera en un solo lado

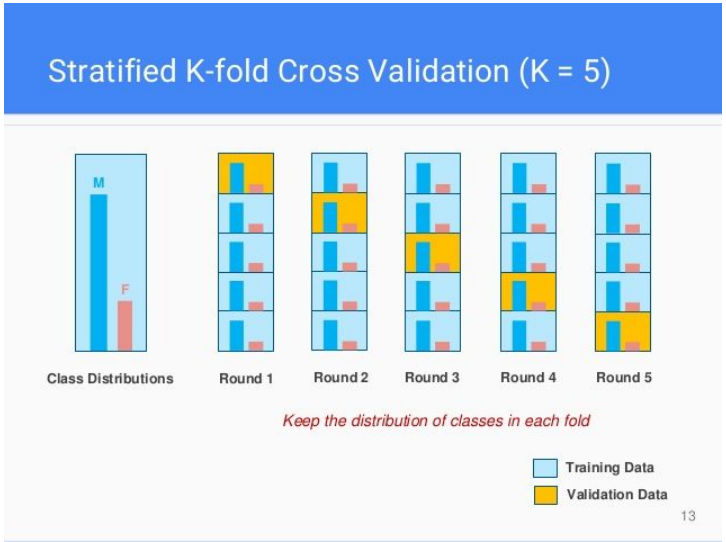


cada color es una persona

Group k-fold: validación cruzada que nunca reparte los datos de un mismo grupo entre entrenamiento y validación.

En estudios con personas, el grupo casi siempre es **el participante**. A veces también el centro, el evaluador o el equipo de registro.

Otras formas de partir los datos



Pregunta guía: ¿tengo la misma información que voy a tener en la realidad?

Estratificada

Mantiene la proporción de cada clase en todas las particiones. Útil cuando una clase es poco frecuente.

Temporal

Si los datos tienen orden en el tiempo, se entrena con el pasado y se valida con el futuro.

Baselines: ¿comparado con qué?

Un resultado solo tiene sentido si lo comparamos con algo más simple.

Azar

¿El modelo es mejor que tirar una moneda?

Clase mayoritaria

¿Es mejor que decir siempre «control»?

Variables simples

¿Aporta algo frente a edad, sexo y educación?

Lo que ya existe

¿Se acerca a la evaluación clínica estándar?

Resumen del módulo 3

Separar antes de empezar

El conjunto de control se guarda y se usa una sola vez.

Validación cruzada

Usa todos los datos para evaluar, por turnos. Mide, no mejora.

Separar por persona

Nunca la misma persona en entrenamiento y validación.

Comparar con baselines

Un número aislado no dice nada.

Módulo 4

Métricas

- Métricas de regresión: MAE y RMSE
- La matriz de confusión
- Accuracy, precisión, sensibilidad, especificidad, F1
- Umbrales, curva ROC y AUC
- ¿Es mejor que el azar?

NeuroTransmitiendo

¿Para qué sirven las métricas?

Durante el desarrollo

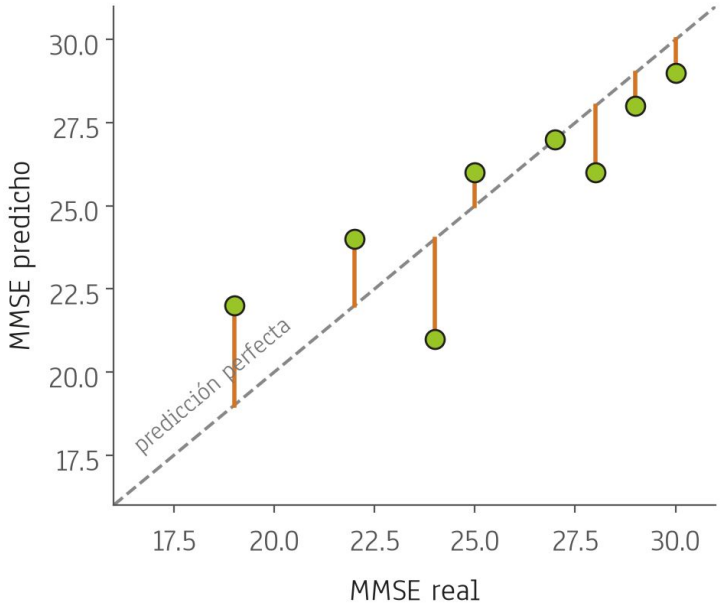
Comparar configuraciones y elegir la mejor. Necesitamos un único número para optimizar.

Al final

Reportar cómo va a funcionar el modelo en la realidad. Conviene dar varias métricas.

Cada métrica responde una pregunta distinta. Elegirla bien es entender qué nos importa del problema.

Regresión: ¿cuánto se equivoca el modelo?



- Cada punto es una persona: su MMSE real y el que predijo el modelo.
- Las líneas naranjas son los errores.
- ¿Sirve contar aciertos exactos? Casi nunca se acierta el valor justo.
- Necesitamos resumir **qué tan lejos** quedan las predicciones.

Error absoluto medio (MAE)

Persona	MMSE real	MMSE predicho	Error	Error absoluto	Error al cuadrado
A	30	29	1	1	1
B	28	26	2	2	4
C	25	26	-1	1	1
D	22	24	-2	2	4

$$\textbf{MAE} = \frac{\text{suma de errores absolutos}}{\text{cantidad de personas}}$$

$$\textbf{MAE} = \frac{1 + 2 + 1 + 2}{4} = \textbf{1.5}$$

En promedio, el modelo se equivoca por **1.5 puntos** de MMSE.

Raíz del error cuadrático medio (RMSE)

Persona	MMSE real	MMSE predicho	Error	Error absoluto	Error al cuadrado
A	30	29	1	1	1
B	28	26	2	2	4
C	25	26	-1	1	1
D	22	24	-2	2	4

$$\text{RMSE} = \sqrt{\frac{\text{suma de errores al cuadrado}}{\text{cantidad de personas}}}$$

$$\text{RMSE} = \sqrt{\frac{1^2 + 2^2 + (-1)^2 + (-2)^2}{4}}$$

$$= 1.58$$

Elevar al cuadrado castiga más los errores grandes. **La raíz vuelve a las unidades originales.**

¿Qué pasa si el modelo se equivoca feo con una persona?

Persona	Real	Predicho	Error absoluto	Al cuadrado
A	30	29	1	1
B	28	26	2	4
C	25	26	1	1
D	22	30	8	64

	Antes	Ahora
MAE	1.5	3.0
RMSE	1.58	4.18

El MAE se duplica, el RMSE casi se triplica. Si los errores grandes son graves, el RMSE lo refleja mejor. Si queremos un promedio robusto, conviene el MAE.

Otras dos medidas que van a encontrar

R^2 (coeficiente de determinación)

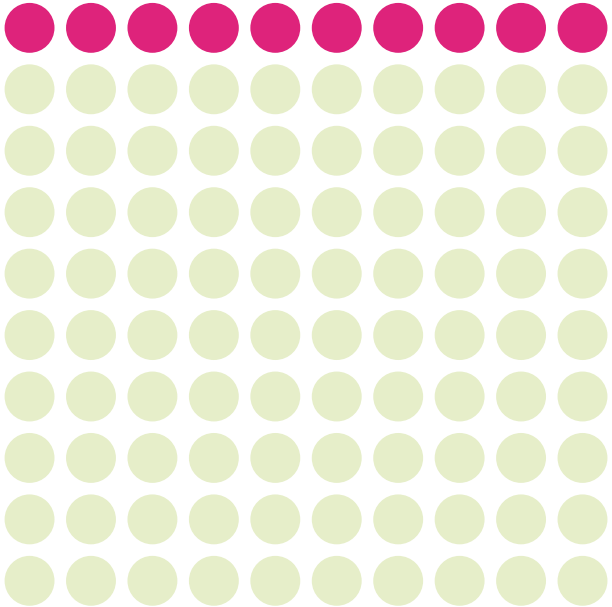
- Compara el modelo con uno trivial que siempre predice el promedio.
- Vale 1 si predice perfecto y 0 si no mejora al promedio.
- Puede ser negativo si el modelo es peor que el promedio.

Correlación de Pearson (r)

- Mide si las predicciones siguen la tendencia de los valores reales.
- **No mide el error:** un modelo que suma 10 puntos a todos tiene r = 1.
- Útil en algunos casos, pero no alcanza sola.

Clasificación: la trampa de la accuracy

10 con deterioro · 90 controles



Accuracy: porcentaje de casos bien clasificados.

Un modelo que dice **"control" a todo el mundo** acierta 90 de 100.

Accuracy = 90 %

Y no detecta **a ningún paciente.**

La matriz de confusión



VP: tiene deterioro y el modelo lo detecta.

FN: tiene deterioro y el modelo dice control.

FP: es control y el modelo dice deterioro.

VN: es control y el modelo dice control.

En inglés: TP, FN, FP y TN.

¿Qué error es peor?

Falso negativo

- Una persona con deterioro queda sin detectar.
- En un screening, puede perder la oportunidad de un diagnóstico temprano.

Falso positivo

- Una persona sana es señalada como paciente.
- Genera angustia, estudios innecesarios y costos.

No hay una respuesta general: depende del uso que le vamos a dar al modelo.

Un ejemplo con números



Evaluamos a 100 personas: 10 con deterioro y 90 controles.

De los 10 pacientes, el modelo detecta **8** y se le escapan **2**.

De los 90 controles, acierta **81** y marca **9** como pacientes.

Exactitud (accuracy)

¿Qué porcentaje del total clasificó bien?



$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}$$

$$\text{Accuracy} = \frac{8 + 81}{100} = 0.89$$

Parece muy bueno, pero mezcla los dos tipos de error y depende de cuántos pacientes haya.

Precisión (precision)



De los que el modelo marcó con deterioro, ¿cuántos lo tenían?

$$\textbf{Precisión} = \frac{VP}{VP + FP}$$

$$\textbf{Precisión} = \frac{8}{8 + 9} = \textbf{0.47}$$

Menos de la mitad de las alarmas son correctas. Importa cuando cada positivo tiene un costo.

Sensibilidad (recall)



De los que tenían deterioro, ¿cuántos detectó el modelo?

$$\textbf{Sensibilidad} = \frac{VP}{VP + FN}$$

$$\textbf{Sensibilidad} = \frac{8}{8 + 2} = \textbf{0.80}$$

Detecta a 8 de cada 10 pacientes. Es la métrica clave para un screening.

Especificidad (specificity)

De los controles, ¿cuántos reconoció como controles?



$$\textbf{Especificidad} = \frac{VN}{VN + FP}$$

$$\textbf{Especificidad} = \frac{81}{81 + 9} = \textbf{0.90}$$

Su complemento, 1 - especificidad = 0.10, es la tasa de falsos positivos. La vamos a usar en la curva ROC.

Mismos conceptos, distintos nombres

En machine learning	En estadística y salud	Fórmula
Recall, true positive rate	Sensibilidad	**VP** / (**VP** + **FN**)
Precision	Valor predictivo positivo	**VP** / (**VP** + **FP**)
True negative rate	Especificidad	**VN** / (**VN** + **FP**)
False positive rate	1 - especificidad	**FP** / (**FP** + **VN**)

En los papers aparecen los dos nombres, a veces mezclados.

F1: un solo número para precisión y sensibilidad

$$F1 = \frac{2 \cdot \text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$$

$$F1 = \frac{2 \cdot 0.47 \cdot 0.80}{0.47 + 0.80} = \mathbf{0.59}$$

¿Por qué no el promedio?

- El promedio de 0.47 y 0.80 da 0.64.
- F1 es una **media armónica**: castiga más al valor bajo.
- Si una de las dos es 0, F1 vale 0.

Ojo: F1 ignora los verdaderos negativos. Por eso puede engañar cuando las clases están desbalanceadas.

Balanced accuracy (exactitud balanceada)

$$\textbf{Balanced accuracy} = \frac{\text{Sensibilidad} + \text{Especificidad}}{2}$$

$$\textbf{Balanced accuracy} = \frac{0.80 + 0.90}{2} = \textbf{0.85}$$

¿Para qué?

- Da el mismo peso a pacientes y controles.
- No se infla cuando una clase es mucho más frecuente.
- Es la que reportamos en el paper del TMT.

Volvamos al modelo que dice “control” a todos

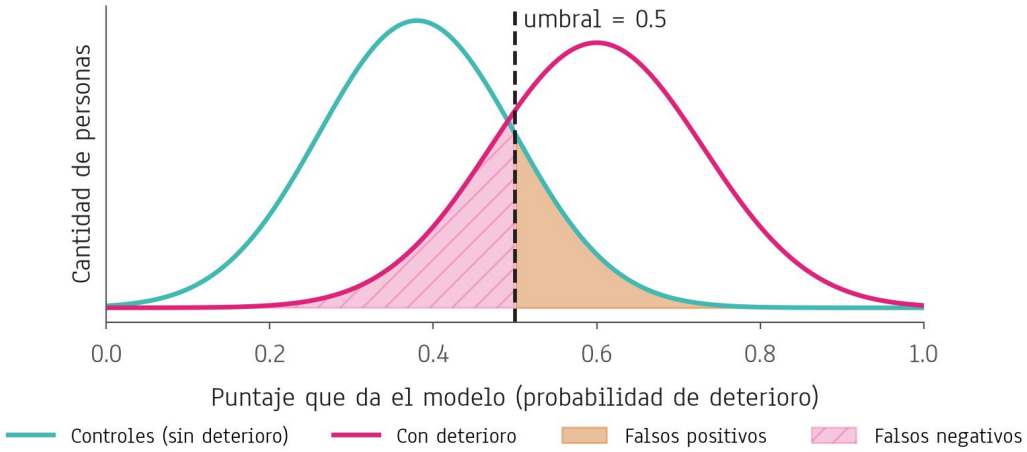
Métrica	Nuestro modelo	“Control” a todos
Accuracy	0.89	0.90
Precisión	0.47	no se puede calcular
Sensibilidad	0.80	0.00
Especificidad	0.90	1.00
F1	0.59	0.00
Balanced accuracy	0.85	0.50

Con accuracy, el modelo inútil “gana”.

Con sensibilidad, F1 o balanced accuracy, queda claro que no sirve.

Por eso conviene reportar varias métricas.

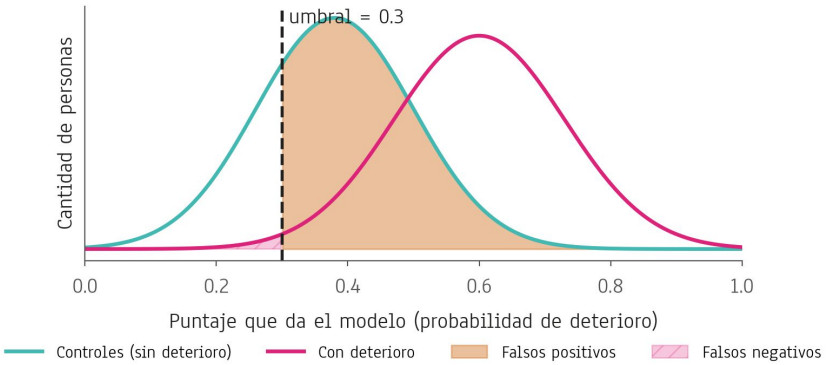
En realidad, el modelo da un puntaje

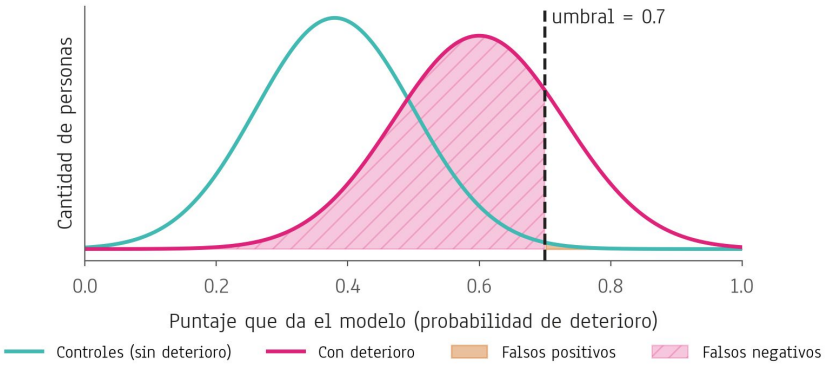


- La mayoría de los modelos devuelven una probabilidad entre 0 y 1.
- Para decidir usamos un **umbral**: si el puntaje lo supera, decimos «deterioro».
- Las dos campanas se superponen: algún error siempre vamos a cometer.

Cada umbral produce una matriz de confusión distinta.

¿Qué pasa si movemos el umbral?

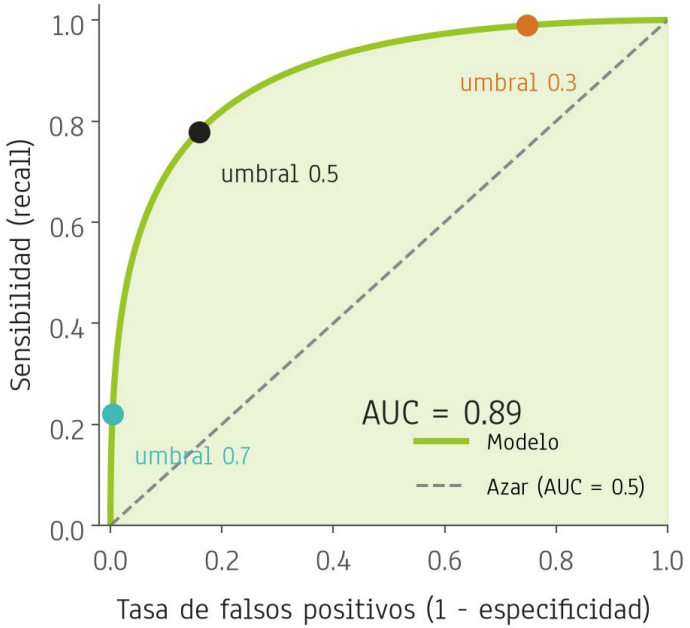




Umbral	Sensibilidad	Especificidad
0.3	0.99	0.25
0.5	0.78	0.84
0.7	0.22	1.00

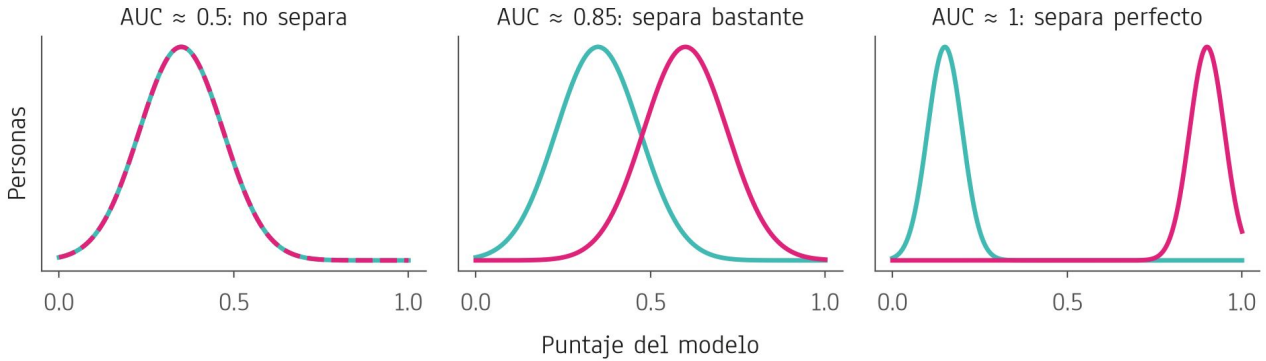
- Umbral bajo: casi no se escapan pacientes, pero hay muchas falsas alarmas.
- Umbral alto: casi no hay falsas alarmas, pero se escapan muchos pacientes.

La curva ROC: todos los umbrales a la vez



- Cada punto de la curva es un umbral distinto.
- **Eje vertical:** sensibilidad.
- **Eje horizontal:** tasa de falsos positivos (1 - especificidad).
- Cuanto más se acerca a la esquina superior izquierda, mejor.
- La diagonal es lo que haría el azar.

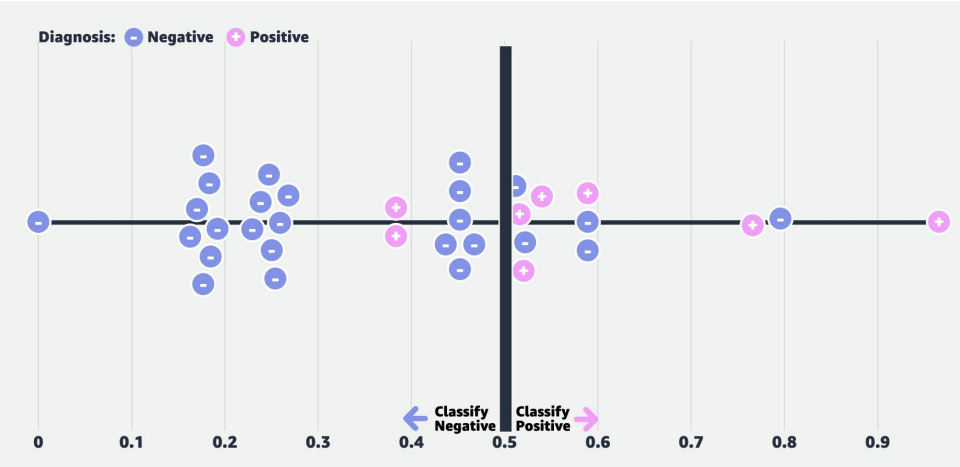
AUC: el área bajo la curva ROC



Interpretación: si tomamos al azar un paciente y un control, el AUC es la probabilidad de que el modelo le dé un puntaje más alto al paciente.

1 = ordena perfecto · 0.5 = azar · no depende del umbral

Para jugar: explicaciones interactivas



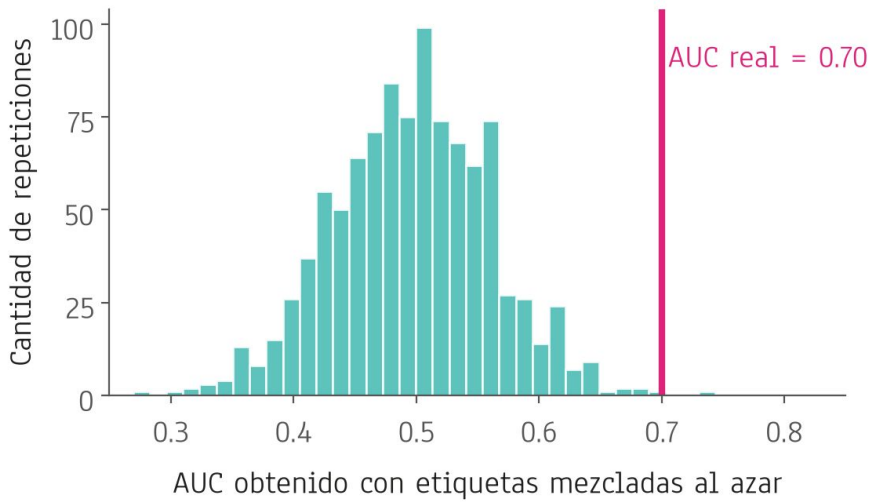
Precisión y sensibilidad con un umbral que se mueve:

mlu-explain.github.io/precision-recall

Curva ROC y AUC:

mlu-explain.github.io/roc-auc

¿Es mejor que el azar? El test de permutaciones



1. Mezclamos las etiquetas al azar y repetimos todo el análisis, por ejemplo 1000 veces.
2. Así vemos qué AUC se obtiene por pura casualidad.
3. El p-valor es la proporción de repeticiones que igualan o superan el AUC real.

¿Qué tan seguro es el resultado? Bootstrap

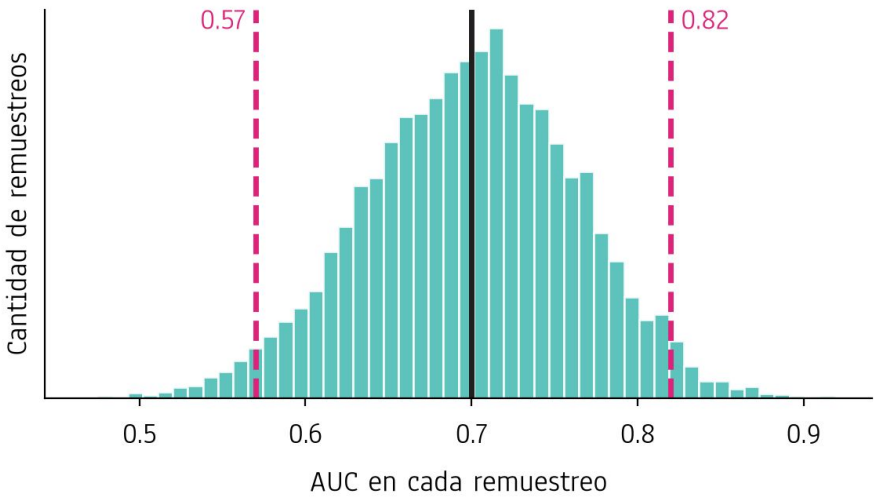


Ilustración con los valores del paper del TMT

1. Seleccionamos aleatoriamente personas de la muestra con reposición: algunas salen repetidas y otras no salen.
2. Calculamos la métrica en esa muestra.
3. Repetimos miles de veces.
4. El 95 % central de los valores es el intervalo de confianza.

Entender el problema define la métrica

Ejemplo: un modelo predice puntajes de 1 a 4 que personas ya anotaron (1 malo, 2 no útil, 3 útil, 4 excelente).

Coincidencia exacta

¿En cuántos casos acierta el puntaje justo?

Con tolerancia de 1

¿En cuántos se equivoca a lo sumo por un punto?

Útil o no útil

Agrupar 3–4 contra 1–2 y calcular precisión y sensibilidad.

Machete de métricas

Métrica	Pregunta	Fórmula
Accuracy	¿Cuánto acierta en total?	(VP + VN) / total
Precisión	¿Cuántas alarmas son correctas?	VP / (VP + FP)
Sensibilidad	¿Cuántos pacientes detecta?	VP / (VP + FN)
Especificidad	¿Cuántos controles reconoce?	VN / (VN + FP)
F1	Resumen de precisión y sensibilidad	2·P·S / (P + S)
Balanced accuracy	Promedio por clase	(Sens + Esp) / 2
AUC	¿Qué tan bien ordena?	Área bajo la curva ROC
MAE	Error promedio en regresión	promedio del error absoluto

Módulo 5

Un caso real: el TMT digital

- Deterioro cognitivo leve y el Trail Making Test
- Del movimiento del mouse a los números
- Cómo evaluamos los modelos
- Resultados leídos con lo aprendido
- Lectura crítica

NeuroTransmitiendo

La pregunta clínica

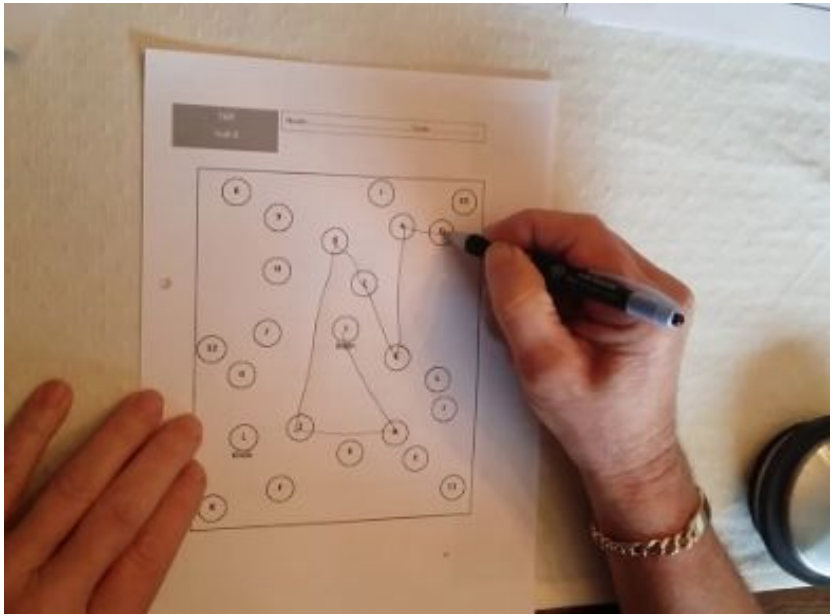
- La carga global de demencia se proyecta casi triple en los próximos treinta años, con mayor impacto en América Latina.
- El **deterioro cognitivo leve** (DCL) es parte del continuo de la enfermedad de Alzheimer.
- Detectarlo temprano importa, pero la evaluación completa es costosa y no siempre está disponible.
- ¿Puede una prueba breve, con una computadora y un mouse comunes, **aportar información para detectarlo?**

74 participantes

41 con DCL

33 controles

Nuestro ejemplo: el Trail Making Test (TMT)



Parte A

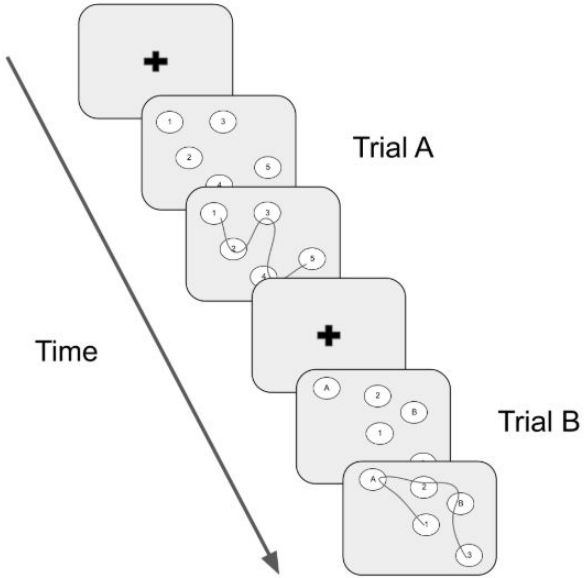
Unir los números en orden: 1, 2, 3...

Parte B

Alternar números y letras: 1, A, 2, B...

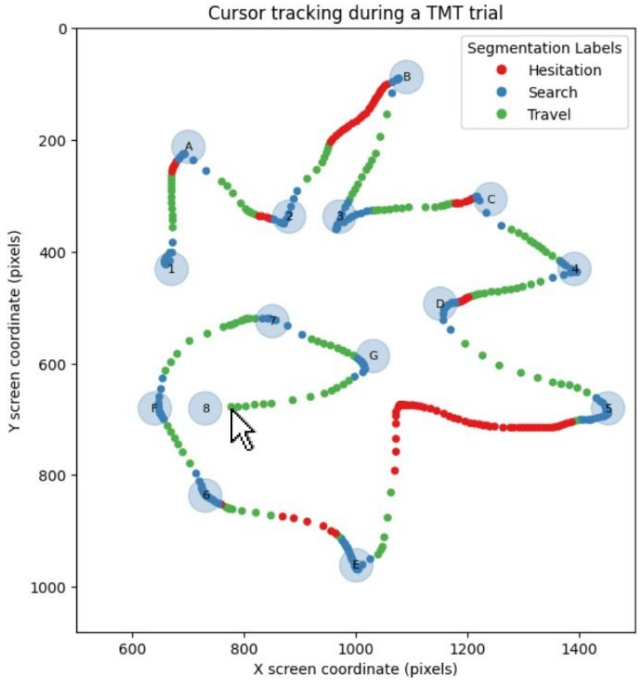
- **Mide:** velocidad de procesamiento y atención en la parte A, flexibilidad cognitiva en la parte B.
- **Medida clásica:** el tiempo total para completar cada parte.

Del Trail Making Test a la computadora



- La misma tarea, ahora en la computadora**.**
- En papel solo se mide el tiempo total. En la computadora se puede registrar mucho más.
- Versión computarizada: 20 ensayos con 15 ítems cada uno, alternando parte A y parte B.
- Se selecciona cada ítem pasando el cursor por encima, sin hacer clic.
- Se registra la posición del mouse unas 60 veces por segundo: **toda la trayectoria.**

Del movimiento a los números



Con la librería [NeuroTask] extrajimos unas 100 variables por persona:

Clásicas	tiempo total, aciertos, errores, cruces
Espaciales	cuánto se desvía del camino ideal
Cinemáticas	velocidad y aceleración del cursor
Por estados	tiempo en búsqueda, desplazamiento y duda

El problema en lenguaje de machine learning

Clasificación

¿La persona tiene DCL o es control?

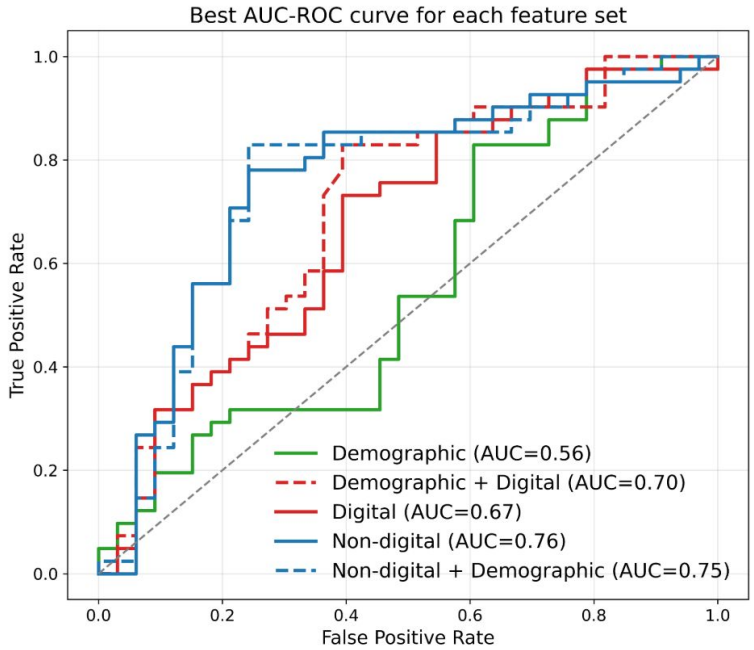
Regresión

Predecir MMSE, TMT en papel y otros puntajes.

Conjunto de variables	Qué incluye	Rol
Demográficas (3)	Edad, sexo, años de educación	Piso
Digitales (100)	Las variables del TMT computarizado	Lo que queremos probar
Neuropsicológicas (6)	MMSE, TMT-A y B, dígito-símbolo, spans, reloj	Techo

Una fila por persona: los ensayos se promediaron por participante. Así nunca hay datos de la misma persona en entrenamiento y validación.

Resultados de la clasificación



0.56
AUC · Demográficas

0.67
AUC · Digitales

0.70
AUC · Digitales + demográficas

0.76
AUC · Neuropsicológicas

Las variables digitales se acercan al techo de la batería clínica.

Leer la tabla con lo que aprendimos

Variables	AUC	Intervalo 95 %	p (permutaciones)	Balanced acc.
Demográficas	0.56	[0.42, 0.69]	0.189	0.60
Digitales	0.67	[0.54, 0.79]	0.007	0.66
Digitales + demográficas	0.70	[0.57, 0.82]	0.002	0.69
Neuropsicológicas	0.76	[0.64, 0.87]	0.001	0.77

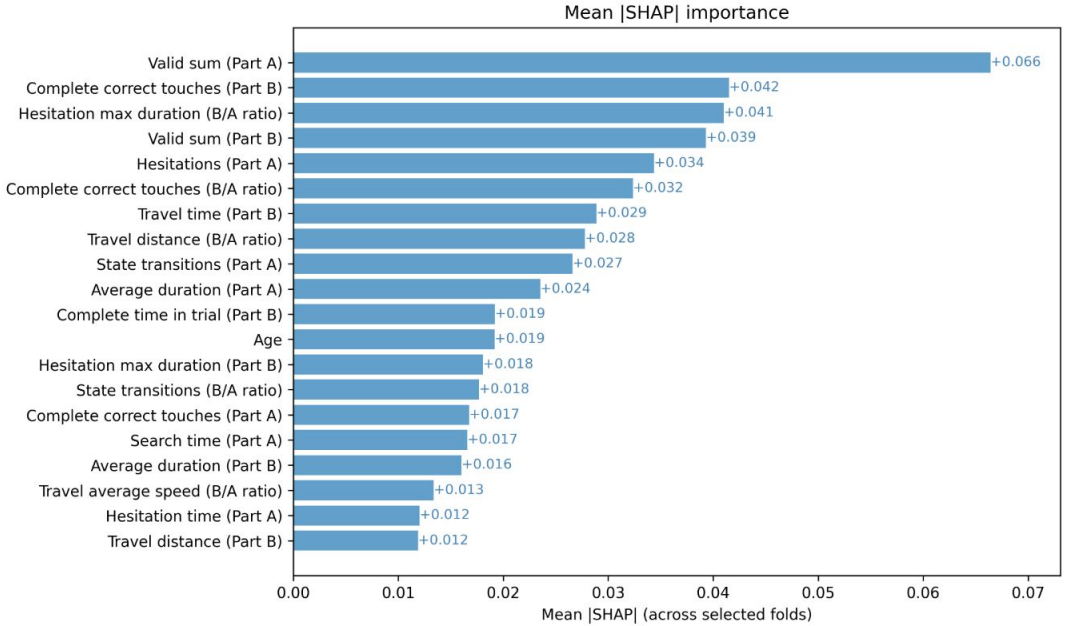
El intervalo incluye 0.5

Las demográficas no superan al azar: el test de permutaciones tampoco es significativo.

Balanced accuracy

Se reporta porque los grupos no son del mismo tamaño: 41 contra 33.

¿Qué variables usó el modelo?



- Los valores SHAP estiman cuánto aporta cada variable a la predicción.
- Las más importantes: cantidad de ensayos válidos, toques correctos y duración máxima de las dudas.
- La edad aparece recién en el puesto doce.

Regresión: predecir los puntajes clínicos

Puntaje a predecir	Mejor modelo	MAE	p	¿Significativo?
MMSE (0 a 30)	Random forest	1.45 puntos	0.004	Sí
Dígito-símbolo (0 a 135)	Lasso	9.47 puntos	0.001	Sí
TMT-A en papel	Elastic net	11.95 s	0.001	Sí
TMT-B en papel	SVR	43.09 s	0.001	Sí
Span directo	Elastic net	0.85	0.027	No, tras corregir
Span inverso y reloj	—	—	> 0.4	No

Usando variables digitales y demográficas, cuatro de siete puntajes se predicen mejor que el azar.

Lectura crítica

Muestra chica

74 personas: los intervalos son anchos y el resultado podría variar en otra muestra.

AUC moderado

0.70 es prometedor para un screening, no un diagnóstico.

¿Generaliza?

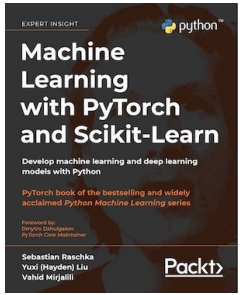
Hace falta probarlo en otros centros, con otras computadoras y otras poblaciones.

Todo el curso en un solo estudio

Concepto	En el estudio del TMT
Tarea, medida, experiencia	Clasificar DCL, medido con AUC, aprendiendo de 74 personas
Clasificación y regresión	Diagnóstico y puntajes clínicos
Separar por persona	Una fila por participante
Validación cruzada	Dejar una persona afuera, con validación anidada
Baselines	Demográficas como piso, batería clínica como techo
Métricas	AUC, balanced accuracy, MAE
Medición de la incertidumbre	Permutaciones e intervalos por bootstrap

Para seguir aprendiendo

- **Müller y Guido (2016).** *Introduction to Machine Learning with Python, capítulo 5.*
- **Poldrack, Huckins y Varoquaux (2020).** *Establishment of best practices for evidence for prediction. JAMA Psychiatry.*
- **Yarkoni y Westfall (2017).** *Choosing prediction over explanation in psychology. Perspectives on Psychological Science.*
- **Raschka (2018).** *Model evaluation, model selection, and algorithm selection in machine learning. arXiv.*
- **Molnar.** *Interpretable Machine Learning, libro en línea.*
- **Juantorena y colaboradores, 2026.** *Machine learning based digital assessment of mild cognitive impairment using mouse trajectories during the trail making test. Scientific Reports.*
- **Raschka (2022).** Machine Learning with PyTorch and Scikit-Learn.



Créditos

Parte del material se basa en:

- Introducción a la IA: con aportes de Joaquín González y Diego Fernández Slezak.
- Machine Learning, curso de Neurotransmitiendo de Daniel M. Low (2022).
- Clases de Evaluación y de Métricas de Pablo Brusco, de la materia Aprendizaje Automático (Departamento de Computación, UBA).
- Figuras del paper del TMT digital publicadas bajo licencia CC BY 4.0.

¿Dudas?

Pueden escribirme a

gjuantorena@gmail.com

Contactarme por Linkedin



¿Qué les pareció el curso? Escribinos a cualquiera de nuestras redes sociales o a ntransmitiendo@gmail.com